

Содержание

Введение.....	3
1. Выполнение заданий по формированию компетенций.....	4
1.1 Программирование на Python: синтаксис и основные операторы.....	4
1.2 Программирование на Python: работа с типами данных	5
1.3 Программирование на Python: работа с файлами и библиотеками	6
1.4 Математика на Python.....	7
1.5 Оптимизация и статистика на Python	7
1.6 Предобработка и первичный анализ данных	9
2. Выполнение основной задачи анализа отзывов.....	11
2.1 Постановка задачи и критерии результата	11
2.2 Организация проекта и воспроизводимость	11
2.3 Загрузка и аудит качества данных	11
2.4 Формирование сопоставимой выборки	12
2.5 Разведочный анализ оценок	12
2.6 Временная динамика.....	14
2.7 Предобработка текста и модель тональности	14
2.8 Выделение категорий жалоб	16
2.9 Статистическая проверка гипотез	17
2.10 Сравнение филиалов «Суши Студии»	18
2.11 Разработка аналитического монитора в Yandex DataLens.....	19
2.12 Бизнес-рекомендации	20
Заключение	21
Список использованных источников	22

Введение

Летняя практика была направлена на закрепление навыков программирования на Python, математической обработки данных, оптимизации, статистического анализа и построения моделей машинного обучения. Основная часть работы посвящена анализу отзывов предприятий общественного питания и сравнению компании «Суши Студия» с конкурентами по оценкам, доле негативных отзывов, характеру жалоб и качеству работы отдельных филиалов.

Цель основной задачи состояла в том, чтобы на основе выгрузки отзывов сформировать объективный портрет целевой компании, выявить ее сильные и слабые стороны, проверить аналитические гипотезы и подготовить практические рекомендации. Итогом стали воспроизводимый ноутбук с подписанными этапами, набор графиков и таблиц, модель классификации тональности, аналитический отчет и интерактивный монитор в Yandex DataLens.

Для достижения цели были решены следующие задачи:

- выполнены шесть заданий по формированию профессиональных компетенций;
- проведен аудит качества исходных данных и сформирована сопоставимая аналитическая выборка;
- исследованы оценки, динамика отзывов, доля негатива и категории жалоб;
- обучена и оценена модель определения тональности текстов;
- статистически проверены различия между брендами, профилями жалоб и филиалами;
- создан BI-монитор для регулярного контроля показателей и сформированы бизнес-рекомендации.

Отчет состоит из двух основных разделов. В первом кратко представлены решения компетентностных заданий, во втором подробно описан ход выполнения основной аналитической задачи, включая постановку гипотез, методы, результаты и интерпретацию.

1. Выполнение заданий по формированию компетенций

1.1 Программирование на Python: синтаксис и основные операторы

Задача: реализовать ввод вещественного числа в заданном диапазоне, вычислить сумму цифр дробной части, построить последовательность Коллатца и обеспечить проверку корректности пользовательского ввода.

Выполненные работы: введено ограничение $8 \leq x \leq 9$, строковое представление числа используется для извлечения дробной части, после чего ее цифры преобразуются в целые значения и суммируются. Для полученного числа последовательность строится циклом до достижения единицы: четное значение делится на два, нечетное заменяется выражением $3n + 1$. Предусмотрены сообщения об ошибках ввода (см. рисунок 1).

```
#Решение
while True:
    try:
        print("Введите число больше 8.0, но меньше 9.0 (не включительно).")
        num = float(input())

        if num > 8.0 and num < 9.0:

            print(f"Введённое число:{num}")

            num_str = str(num)
            fr = num_str.split('.')[1]
            sum_n = sum(int(i) for i in fr)
            print(f"Сумма цифр после запятой {sum_n}")

            sequence = [sum_n]

            while sum_n != 1:
                if sum_n % 2 == 0:
                    sum_n = sum_n // 2
                else:
                    sum_n = 3 * sum_n + 1
                sequence.append(sum_n)
            print(f"Последовательность: {sequence}")

            steps = len(sequence) - 1
            print(f"Количество шагов в последовательности: {steps}")

            max_sum_n = max(sequence)
            print(f"Самое большое число в последовательности: {max_sum_n}")
            break

        else:
            print("Введите другое число!")

    except ValueError:
        print("Вводите только число!")
```

Рисунок 1 – Исходный код для построения последовательность Коллатца

Результат: для примера 8,99 сумма цифр дробной части равна 18. Последовательность содержит 20 переходов, максимальное значение равно 52, конечное значение – 1 (см. рисунок 2).

```
Введите число больше 8.0, но меньше 9.0 (не включительно).  
8.99  
Введённое число:8.99  
Сумма цифр после запятой 18  
Последовательность: [18, 9, 28, 14, 7, 22, 11, 34, 17, 52, 26, 13, 40, 20, 10, 5, 16, 8, 4, 2, 1]  
Количество шагов в последовательности: 20  
Самое большое число в последовательности: 52
```

Рисунок 2 – Результат построения последовательности Коллатца.

1.2 Программирование на Python: работа с типами данных

Задача: обработать списки чисел и строк, выполнить фильтрацию, нормализацию и агрегирование, а также извлечь показатели из структуры JSON.

Выполненные работы: применены списковые включения, срезы, множества, сортировка, индексация и функции агрегации. Строковые значения очищались от лишних пробелов и приводились к единому регистру. Для JSON-данных выполнены преобразование денежного баланса в число, расчет среднего возраста, поиск уникальных пользователей и определение самой ранней даты регистрации (см. рисунок 3).

- в первом числовом массиве найдено 13 неотрицательных элементов;
- сумма отрицательных значений третьего массива составила –75 578;
- получено 485 уникальных значений, выделена десятка максимальных значений от 290 до 300;
- сумма элементов по индексам Фибоначчи равна –2 970;
- по данным JSON общий баланс равен 14 928,56 доллара, средний возраст – 29,5 года, число уникальных людей – 22;
- самая ранняя регистрация относится к Imelda Alexander и датирована 31.08.2014 (см. рисунок 4).

Результат: закреплены навыки выбора подходящей структуры данных, безопасного преобразования строковых значений и получения сводных характеристик без ручного перебора элементов.

```

#Решение
#1
arr1 = [x for x in arr1 if x >= 0]
print("1 ", len(arr1))

#2
arr2 = [' '.join(s.split()) for s in arr2]
print("2 ", arr2)

#3
sum_neg = sum(x for x in arr3 if x < 0)
print("3 ", sum_neg)

#4
arr3_unique = list(set(arr3))
print("4 ", len(arr3_unique))

#5
arr3_sorted = sorted(arr3_unique)
top_10 = arr3_sorted[-10:] if len(arr3_sorted) >= 10 else arr3_sorted
print("5 ", top_10)

#6
max_index = len(arr3_sorted) - 1
fib = set()
a, b = 0, 1
while a <= max_index:
    fib.add(a)
    a, b = b, a + b
sum_fib = sum(arr3_sorted[i] for i in fib if i <= max_index)
print("6 ", sum_fib)

```

```

#Решение
import json
import time
accounts = json.loads(data)

#1
total_balance = sum(
    float(acc['balance'].replace('$', '').replace(',', ''))
    for acc in accounts
)

print(f"Общая сумма балансов: ${total_balance:,.2f}")

#2
ages = [acc['age'] for acc in accounts]
avg_age = sum(ages) / len(ages)
print(f"Средний возраст: {avg_age:.2f} лет")

#3
people = set()
for acc in accounts:
    people.add(acc['name'])
    for f in acc['friends']:
        people.add(f['name'])
print(f"Количество различных людей: {len(people)}")

#4
earliest = None
earliest_ts = None
for acc in accounts:
    dt_str = acc['registered'].split(' ')[0]
    t = time.strptime(dt_str, "%Y-%m-%dT%H:%M:%S")
    ts = time.mktime(t)
    if earliest_ts is None or ts < earliest_ts:
        earliest_ts = ts
        earliest = acc
print("Самый ранний аккаунт:")
print("Имя:", earliest['name'])
print("Дата регистрации:", earliest['registered'])

```

Рисунок 3 – Код для обработки данных.

```

1 13
2 ['Король пики', 'дАМа крести', 'Туз черви', 'Валет буби']
3 -75578
4 485
5 [290, 292, 293, 294, 295, 296, 297, 298, 299, 300]
6 -2970

```

```

Общая сумма балансов: $14,928.56
Средний возраст: 29.50 лет
Количество различных людей: 22
Самый ранний аккаунт:
Имя: Imelda Alexander
Дата регистрации: 2014-08-31T07:36:09 -09:00

```

Рисунок 4 – Результаты обработки данных.

1.3 Программирование на Python: работа с файлами и библиотеками

Задача: распаковать архив с файлами разных форматов, унифицировать их чтение, классифицировать числовые значения, сохранить результат в JSON и получить внешние данные через HTTP API.

Выполненные работы: содержимое архива распределено по расширениям, для CSV, TXT и JSON реализованы отдельные обработчики, возвращающие данные в едином формате. Числа классифицированы на неотрицательные целые, отрицательные целые и вещественные. Дополнительно выполнен запрос к JSONPlaceholder, ответ преобразован в DataFrame и проанализирован средствами pandas (см. таблицу 1).

Таблица 1 – Результат решения задачи.

Показатель	Значение
Количество CSV-файлов	255
Количество TXT-файлов	112
Количество JSON-файлов	23
Неотрицательные целые	6 550; сумма 195 673; min 1; max 100

Показатель	Значение
Вещественные	12 600; сумма –2 795,2898; min – 49,966; max 49,999
Публикации JSONPlaceholder	10 записей на пользователя; средняя длина 160,64 символа

Результат: сформирован файл numbers.json со сводными метриками; показана возможность объединять файловые источники и данные API в одном аналитическом процессе.

1.4 Математика на Python

Задача: выполнить векторные и матричные операции, решить систему линейных уравнений, построить функцию и вычислить градиент.

Выполненные работы: с помощью NumPy вычислены скалярное произведение, сумма векторов, умножение матрицы на число и транспонирование. Система $(B^T A^{-1})x = 3a + b$ решена методами линейной алгебры. Для функции $f(x) = \sin x + \cos x + \ln x$ построен график на отрезке $[1; 10]$ (см. рисунок 5), а частные производные использованы для вычисления градиента функции двух переменных.

- скалярное произведение исходных векторов равно 20;
- сумма векторов равна $[6, 2, 0, 9]$;
- решение матричной системы $x = [-14,875; -42,55; 26,2; 15,625]$;
- градиент в точке $(-5; -2)$ равен $[0,08366219; 0,40929743]$.




Рисунок 4 – График функции.

1.5 Оптимизация и статистика на Python

Задача: найти минимум функции градиентным спуском и получить статистические характеристики двух выборок.

Выполненные работы: реализован итерационный градиентный спуск с контролем нормы градиента и максимального числа итераций (см. рисунок 5). Характер стационарной точки проверен по собственным значениям матрицы

Гессе. Для двух выборок рассчитаны среднее, дисперсия и доверительный интервал, построены гистограммы и выполнен критерий Шапиро–Уилка (см. рисунок 6).

Результат: градиентный спуск сошелся за 134 итерации в точке [4,48767909; 2,77260785], значение функции равно 0,613571. Положительные собственные значения Гессиана 0,9252 и 0,8026 подтверждают локальный минимум. Для обеих статистических выборок нормальность отвергается на уровне значимости 0,05; вывод о глобальности найденного минимума без дополнительного анализа функции не делается.

```
import numpy as np

def f(x):
    return np.sin(x[0]) + np.cos(x[1]) + np.log(x[0] * x[1])

def grad(x):
    x1, x2 = x
    df_dx = np.cos(x1) + 1 / x1
    df_dy = -np.sin(x2) + 1 / x2
    return np.array([df_dx, df_dy])

alpha = 0.1
x = np.array([2.0, 3.0])

eps = 1e-6
max_iter = 10000

for i in range(max_iter):
    g = grad(x)
    x_new = x - alpha * g

    if np.linalg.norm(x_new - x) < eps:
        break

    x = x_new

g_final = grad(x)

x1, x2 = x
H = np.array([
    [-np.sin(x1) - 1/x1**2, 0],
    [0, -np.cos(x2) - 1/x2**2]
])

eigvals = np.linalg.eigvals(H)
```

```
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats

alpha = 0.97

x1 = np.array(arr1)

mean1 = np.mean(x1)
var1 = np.var(x1, ddof=1)
n1 = len(x1)
s1 = np.std(x1, ddof=1)
t1 = stats.t.ppf((1 + alpha)/2, df=n1-1)
margin1 = t1 * s1 / np.sqrt(n1)
ci1 = (mean1 - margin1, mean1 + margin1)

p1 = stats.shapiro(x1)

x2 = np.array(arr2)

mean2 = np.mean(x2)
var2 = np.var(x2, ddof=1)
n2 = len(x2)
s2 = np.std(x2, ddof=1)
t2 = stats.t.ppf((1 + alpha)/2, df=n2-1)
margin2 = t2 * s2 / np.sqrt(n2)
ci2 = (mean2 - margin2, mean2 + margin2)

p2 = stats.shapiro(x2)
```

Рисунок 5 – Реализация итерационного градиентного спуска.




Рисунок 6 – Результат расчета статистических характеристик двух выборок.

1.6 Предобработка и первичный анализ данных

Задача: провести разведочный анализ набора House Rent, обработать выбросы, исследовать зависимости и построить множественную линейную регрессию.

Выполненные работы: проанализированы 4 746 наблюдений без пропусков; исследованы распределения числовых и категориальных признаков, рассчитана корреляционная матрица. Выбросы удалены по межквартильному размаху, после чего осталось 4 078 строк. Категориальные признаки закодированы методом one-hot encoding, дата и этаж преобразованы в аналитические признаки. Модель уточнялась путем последовательного исключения статистически незначимых переменных.




Рисунок 7 – Связь основных количественных признаков с арендной платой.

Результат: наибольшая из рассмотренных парных корреляций с арендной платой наблюдается у количества ванных комнат (0,4412), затем у площади (0,4136) и числа комнат (0,3697) (см. рисунок 7). Сильной одиночной линейной зависимости не найдено, однако итоговая многофакторная модель с

18 признаками объясняет около 69,2 % вариации арендной платы (см. рисунок 8).

Итоговая модель:

OLS Regression Results						
Dep. variable:	rent	R-squared:	0.691			
Model:	OLS	Adj. R-squared:	0.590			
Method:	least squares	F-statistic:	708.4			
Date:	Mon, 22 Jun 2016	Prob (F-statistic):	0.00			
Time:	12:17:06	log-likelihood:	-42093.			
No. Observations:	4878	AIC:	8.428e+04			
Of residuals:	4866	BIC:	8.429e+04			
Of model:	12					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[9.025	8.975
const	1052.4553	667.541	1.575	0.060	7043.669	9641.362
bmk	3611.8216	278.858	12.949	0.000	3064.967	4157.776
Size	7.8911	8.441	0.935	0.000	6.228	7.956
Bathroom	2633.1899	297.686	8.845	0.000	2049.482	3216.73
Floor_Num	340.9677	18.462	18.462	0.000	205.568	476.376
City_Delhi	3896.4458	298.618	13.050	0.000	2316.138	5476.754
City_Hyderabad	-1983.2811	325.586	-6.067	0.000	-2541.411	-1265.027
City_Kolkata	-1840.2118	396.392	-4.641	0.000	-2625.358	-1071.066
City_Punjab	1.755e+06	448.067	39.120	0.000	1.028e+06	2.482e+06
Furnishing_Status_Semi-Furnished	-3570.2384	275.436	-12.964	0.000	-4100.258	-2039.218
Furnishing_Status_Unfurnished	-4792.1191	381.846	-12.550	0.000	-5540.746	-4043.493
Tenant_Preferred_Bachelors/Family	-679.2480	322.488	-2.105	0.035	-1312.177	-47.309
Tenant_Preferred_Family	-2866.8085	486.838	-5.897	0.000	-3820.588	-1911.508
Point of Contact_Contact Owner	-7840.4673	325.713	-24.072	0.000	-8479.844	-7201.090
Omnibus:	458.394	Statistik-Watson:	2.013			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	1368.918			
Skew:	0.681	Prob(JB):	1.22e-293			
Kurtosis:	5.548	Cond. No.	0.44e+03			

$R^2 = 0.6914$ – модель объясняет 69.1% дисперсии Rent

Значимые признаки:

City_Mumbai: 17760.75 (p=0.0000)
 BHK: 3611.02 (p=0.0000)
 City_Delhi: 3896.45 (p=0.0000)
 Bathroom: 2633.11 (p=0.0000)
 Floor_Num: 340.97 (p=0.0000)
 Size: 7.09 (p=0.0000)
 Tenant_Preferred_Bachelors/Family: -679.94 (p=0.0351)
 City_Hyderabad: -1983.24 (p=0.0000)
 City_Kolkata: -2648.21 (p=0.0000)
 Tenant_Preferred_Family: -2866.03 (p=0.0000)
 Furnishing_Status_Semi-Furnished: -3570.24 (p=0.0000)
 Furnishing_Status_Unfurnished: -4792.12 (p=0.0000)
 Point of Contact_Contact Owner: -7840.47 (p=0.0000)

Рисунок 8 –Характеристики итоговой модели.

2. Выполнение основной задачи анализа отзывов

2.1 Постановка задачи и критерии результата

Основная задача сформулирована как анализ отзывов точки общественного питания для сравнения целевой компании с конкурентами. Объектом исследования выбрана сеть «Суши Студио». В качестве конкурентов рассматривались «Суши Точка», Sushi Holl, «Сушишоп», «Суши мастер», «Мистер лосось» и «Arigato».

Задача: очистить данные, исследовать оценки и тексты отзывов, определить причины негатива, проверить различия статистическими методами, сравнить филиалы и представить результаты в виде аналитического монитора и бизнес-рекомендаций.

В работе проверялись пять содержательных гипотез: различается ли средняя оценка целевой компании и конкурентов; ниже ли у «Суши Студио» доля негативных отзывов; отличается ли профиль жалоб; имеются ли различия между филиалами; существует ли выраженная временная динамика средней оценки.

2.2 Организация проекта и воспроизводимость

Для анализа использованы Python, pandas и NumPy; для статистических тестов – SciPy и statsmodels; для визуализации – Matplotlib и Seaborn; для модели тональности – scikit-learn.

2.3 Загрузка и аудит качества данных

Исходная выгрузка содержит 94 069 отзывов. Первичный аудит включал проверку состава столбцов, типов данных, пропусков, корректности дат и оценок, а также поиск точных дубликатов (см. таблицу 2).

Таблица 2 – Результат первичного анализа данных

Проверка	Результат
Исходное число строк	94 069
Точные дубликаты	2 350
Строк после удаления дубликатов	91 719
Пропуски адреса	41
Некорректная или отсутствующая дата	66
Некорректная или отсутствующая оценка	61
Отсутствующий текст отзыва	3 275
Итоговая сопоставимая выборка	6 364

Удаление точных дубликатов исключило повторный учет одних и тех же отзывов. Строки с критическими дефектами ключевых полей не использовались при расчетах. Названия компаний и адреса были

нормализованы, даты преобразованы в единый формат, оценки ограничены допустимым диапазоном.

2.4 Формирование сопоставимой выборки

Для корректного сравнения отобраны отзывы по семи брендам за период с 01.01.2020 по 02.08.2023. Итоговая выборка включает 6 364 наблюдения. Основная часть относится к «Суши Студии», поэтому вместе со средними значениями анализировались объем выборки и доля отрицательных оценок (см. таблицу 3).

Таблица 3 – Результат первичного анализа отзывов.

Компания	Отзывы	Средняя оценка	Негативные отзывы
Суши Студия	4 054	4,63	8,1 %
Суши Точка	968	4,67	7,6 %
Мистер лосось	237	4,65	8,4 %
Sushi Holl	272	4,15	17,3 %
Arigato	211	4,02	22,7 %
Сушишоп	288	3,77	28,5 %
Суши мастер	334	2,31	66,5 %

2.5 Разведочный анализ оценок

Распределение оценок (см. рисунок 9) показывает выраженное преобладание высоких значений, особенно у трех лидирующих брендов. Одновременно для компаний с более низкой средней оценкой заметно растет доля оценок 1–2 (см. рисунок 10), что делает долю негативных отзывов более интерпретируемым показателем качества, чем одно среднее значение.




Рисунок 9 – Распределение оценок по компаниям.




Рисунок 10 – Средняя оценка компаний в сопоставимой выборке.

«Суши Студии» входит в группу лидеров: средняя оценка 4,63 лишь немного ниже показателей «Суши Точки» и «Мистера лосося». Существенное преимущество наблюдается относительно Sushi Holl, Arigato, «Сушишопа» и особенно «Суши мастера» (см. рисунок 10).




Рисунок 11 – Доля негативных отзывов по компаниям.

Доля негативных отзывов «Суши Студии» равна 8,1 %. Для совокупности конкурентов показатель составляет 21,3 %, то есть разница достигает 13,2 процентного пункта (см. рисунок 11). При этом «Суши Точка» показывает близкий и немного лучший результат – 7,6 %, что задает реалистичный ориентир для дальнейшего улучшения.

2.6 Временная динамика

Для исключения влияния разного количества отзывов в месяц динамика анализировалась по среднемесячной оценке (см. рисунок 12). Дополнительно учитывался объем отзывов, поскольку в месяцы с малым числом наблюдений оценка менее устойчива.




Рисунок 12 – Динамика средней оценки «Суши Студии» по месяцам.

2.7 Предобработка текста и модель тональности

Тексты приведены к нижнему регистру, очищены от лишних символов и токенизированы. Для снижения числа словоформ применена лемматизация `ru morphology3`. Результаты предобработки кэшировались, чтобы повторный запуск ноутбука не требовал заново выполнять наиболее ресурсоемкий этап.

В качестве целевой метки использована оценка: 1–2 обозначают отрицательный отзыв, 4–5 – положительный, нейтральные оценки 3 исключены из обучения. Признаки текстов сформированы методом TF-IDF, классификатором выбрана логистическая регрессия с балансировкой классов. Обучающая выборка содержит 4 979 отзывов, тестовая – 1 245.



Рисунок 13 – Матрица ошибок модели тональности.

На тестовой выборке ассигасу составила 0,9671, F1 для положительного класса – 0,9809, ROC-AUC – 0,9887 (см. рисунок 13). Высокие значения подтверждают пригодность модели для автоматической разметки текстов в рамках данного набора данных. Ограничением является то, что целевая метка получена из пользовательской оценки, а не из независимой ручной разметки.

2.8 Выделение категорий жалоб

Негативные отзывы классифицированы по словарю тематических признаков. Один отзыв может содержать несколько проблем, поэтому суммы долей по категориям не обязаны равняться 100 %. Используются категории вкуса, качества еды, скорости и доставки, сервиса и персонала, комплектности заказа, цены и ценности, упаковки, чистоты, интерьера и атмосферы (см. рисунок 14).




Рисунок 14 – Сравнение категорий жалоб целевой компании и конкурентов.

Таблица 4 – Результат первичного анализа отзывов.

Категория	Суши Студии	Конкуренты
Скорость и доставка	52,0 %	45,0 %
Сервис и персонал	47,7 %	22,9 %
Вкус	28,6 %	40,4 %
Качество еды	28,6 %	31,6 %
Интерьер и атмосфера	17,3 %	1,4 %
Комплектность заказа	10,3 %	12,0 %
Цена и ценность	8,8 %	9,5 %
Чистота	5,5 %	1,8 %
Упаковка	4,0 %	5,5 %

Ключевая особенность «Суши Студии» – высокая доля жалоб на скорость и доставку, а также на сервис и персонал (см. таблицу 4). Претензии ко вкусу и качеству еды встречаются реже, чем у конкурентов. Категории интерьера и чистоты выражены сильнее, что может быть связано с большим числом отзывов о залах и конкретных филиалах целевой сети.

2.9 Статистическая проверка гипотез

Статистические результаты дополняют описательные графики (см. рисунок 15). Они подтверждают конкурентное преимущество целевой компании по доле негатива, но одновременно показывают, что преимущества относительно двух сильнейших конкурентов недостаточно выражены.

- **H1:** распределение оценок «Суши Студии» отличается от каждого конкурента.
- **H2:** доля негативных отзывов отличается от объединённой группы конкурентов.
- **H3:** структура жалоб отличается от конкурентов.
- **H4:** филиалы «Суши Студии» имеют одинаковое распределение оценок.
- **H5:** месячная средняя оценка компании имеет монотонный тренд.

	hypothesis	comparison	metric	target_value	comparison_value	effect	p_adjusted	Вывод
0	H1	Суши Студии — Суши Точка	распределение оценок	4.6300	4.6663	-0.0167	0.3096	Значимое различие не обнаружено
1	H1	Суши Студии — Sushi Hall	распределение оценок	4.6300	4.1544	0.1889	0.0000	Различие статистически значимо
2	H1	Суши Студии — Сушишоп	распределение оценок	4.6300	3.7743	0.2530	0.0000	Различие статистически значимо
3	H1	Суши Студии — Суши мастер	распределение оценок	4.6300	2.3144	0.6207	0.0000	Различие статистически значимо
4	H1	Суши Студии — Мастер лосось	распределение оценок	4.6300	4.6540	-0.0248	0.3096	Значимое различие не обнаружено
5	H1	Суши Студии — Arigato	распределение оценок	4.6300	4.0237	0.1667	0.0000	Различие статистически значимо
6	H2	Суши Студии — конкуренты вместе	доля негативных отзывов	0.0812	0.2134	-0.1323	0.0000	Различие статистически значимо
7	H3	Суши Студии — конкуренты вместе	жалоба: качество еды	0.2857	0.3164	-0.0307	1.0000	Значимое различие не обнаружено
8	H3	Суши Студии — конкуренты вместе	жалоба: вкус	0.2857	0.4037	-0.1179	0.0038	Различие статистически значимо
9	H3	Суши Студии — конкуренты вместе	жалоба: скорость и доставка	0.5198	0.4503	0.0695	0.2540	Значимое различие не обнаружено
10	H3	Суши Студии — конкуренты вместе	жалоба: сервис и персонал	0.4772	0.2292	0.2480	0.0000	Различие статистически значимо
11	H3	Суши Студии — конкуренты вместе	жалоба: цена и ценность	0.0881	0.0953	-0.0072	1.0000	Значимое различие не обнаружено
12	H3	Суши Студии — конкуренты вместе	жалоба: комплектность заказа	0.1033	0.1197	-0.0163	1.0000	Значимое различие не обнаружено
13	H3	Суши Студии — конкуренты вместе	жалоба: упаковка	0.0395	0.0548	-0.0153	1.0000	Значимое различие не обнаружено
14	H3	Суши Студии — конкуренты вместе	жалоба: чистота	0.0547	0.0183	0.0365	0.0244	Различие статистически значимо
15	H3	Суши Студии — конкуренты вместе	жалоба: интерьер и атмосфера	0.1733	0.0142	0.1591	0.0000	Различие статистически значимо
16	H4	филиалы Суши Студии	распределение оценок	NaN	NaN	NaN	0.0000	Различие статистически значимо
17	H5	динамика Суши Студии	месячная средняя оценка	4.0479	3.2727	0.4777	0.0018	Различие статистически значимо

Рисунок 15 – Сравнение категорий жалоб целевой компании и конкурентов.

2.10 Сравнение филиалов «Суши Студио»

Агрегирование по адресам выявило заметную неоднородность результатов. Для управленческой интерпретации одновременно рассматривались средняя оценка, число отзывов и доля негатива. Филиалы с малым объемом наблюдений не использовались как основной ориентир без дополнительной проверки (см. рисунок 16).




Рисунок 16 – Сравнение ключевых филиалов «Суши Студио».

Таблица 5 – Результат первичного анализа отзывов.

Филиал	Отзывы	Средняя оценка	Доля негатива
Ядринцева, 8а	2 081	4,72	6,0 %
Седова, 18	1 537	4,62	8,2 %
Байкальская, 253Б	436	4,24	18,1 %

Лучший устойчивый результат показывает филиал на Ядринцева, 8а (см. таблицу 5): высокая оценка сочетается с большим числом отзывов и минимальной долей негатива. Филиал на Байкальской, 253Б заметно отстает: доля отрицательных отзывов более чем в три раза выше. Для него требуется отдельный разбор причин жалоб и контроль корректирующих действий.

2.11 Разработка аналитического монитора в Yandex DataLens

Для регулярного использования результатов создан интерактивный монитор «Монитор отзывов Суши Студии» (см. рисунок 17). В него включены визуализации средней оценки по брендам, динамики показателей по месяцам, доли негативных отзывов, категорий жалоб и средней оценки филиалов. Селектор бренда позволяет переходить от общего обзора к анализу выбранной компании.




Рисунок 17 – Аналитический монитор отзывов в Yandex DataLens.

Доля негативных отзывов рассчитывается как среднее бинарного признака `is_negative`, умноженное на 100. Категории жалоб агрегируются по основной теме негативного отзыва, а сравнение филиалов строится по средней оценке для нормализованного адреса. Фильтр бренда применяется ко всем связанным графикам, поэтому руководитель может быстро проверить, за счет каких компаний, периодов и адресов формируется общий показатель.

2.12 Бизнес-рекомендации

На основании описательных и статистических результатов сформированы следующие рекомендации:

- ежемесячно контролировать долю негативных отзывов в разрезе брендов, филиалов и категорий жалоб, фиксируя изменение после управленческих действий;
- провести разбор жалоб на скорость и доставку: разделить время приготовления, передачу курьеру и фактическое время доставки, установить нормативы и причины отклонений;
- усилить контроль сервиса и работы персонала, поскольку эта категория встречается в 47,7 % негативных отзывов целевой компании;
- подготовить план улучшения филиала на Байкальской, 253Б и сопоставить его процессы с филиалом на Ядринцева, 8а;
- сохранить сильные стороны продукта: жалобы на вкус и качество еды встречаются у «Суши Студио» реже, чем в совокупности у конкурентов;
- после накопления новых данных повторить статистические тесты и отдельно проверить филиалы с малой выборкой.

При внедрении рекомендаций следует измерять не только изменение средней оценки, но и динамику доли негатива и конкретных категорий жалоб. Это позволит отличить случайные колебания рейтинга от устойчивого улучшения клиентского опыта.

Заключение

В ходе практики выполнены шесть заданий по формированию компетенций: от базового программирования и обработки структур данных до математических вычислений, оптимизации, статистики, файловых операций, предобработки и регрессионного анализа. Решения оформлены в ноутбуках Jupyter с разделением на этапы, комментариями и зафиксированными результатами.

Основная задача анализа отзывов выполнена полностью. Из 94 069 исходных строк после аудита и отбора сформирована сопоставимая выборка из 6 364 отзывов по семи брендам за 2020–2023 годы. «Суши Студия» получила среднюю оценку 4,63 и долю негатива 8,1 %, что заметно лучше совокупного показателя конкурентов 21,3 %. При этом сеть практически сопоставима с двумя сильнейшими конкурентами, поэтому дальнейший рост требует адресной работы, а не общих изменений продукта.

Анализ текстов показал, что основные зоны риска связаны со скоростью и доставкой, сервисом и персоналом. Сравнение филиалов выявило сильный результат на Ядринцева, 8а и проблемную позицию филиала на Байкальской, 253Б. Модель TF-IDF и логистической регрессии достигла ROC-AUC 0,9887, а статистические тесты подтвердили различия в доле негатива, профиле жалоб, работе филиалов и положительной временной динамике.

Итоговый монитор Yandex DataLens объединяет ключевые показатели и обеспечивает переход от общего сравнения брендов к анализу негатива, категорий жалоб и филиалов. Подготовленные рекомендации ориентированы на измеримые действия и могут быть проверены повторным анализом после появления новых отзывов.

Полученный опыт закрепил теоретические знания в области Python разработки, машинного обучения, анализа данных.

Список использованных источников

1. Документация Python. URL: <https://docs.python.org/3/> (дата обращения: 07.09.2026).
2. Документация NumPy. URL: <https://numpy.org/doc/> (дата обращения: 07.09.2026).
3. Документация pandas. URL: <https://pandas.pydata.org/docs/> (дата обращения: 07.09.2026).
4. Документация SciPy. URL: <https://docs.scipy.org/doc/scipy/> (дата обращения: 07.09.2026).
5. Документация scikit-learn. URL: <https://scikit-learn.org/stable/> (дата обращения: 07.09.2026).
6. Документация statsmodels. URL: <https://www.statsmodels.org/stable/> (дата обращения: 07.09.2026).
7. Документация Matplotlib. URL: <https://matplotlib.org/stable/> (дата обращения: 07.09.2026).
8. Документация Seaborn. URL: <https://seaborn.pydata.org/> (дата обращения: 07.09.2026).
9. Документация pumorphu3. URL: <https://pypi.org/project/pumorphu3/> (дата обращения: 07.09.2026).
10. Документация Yandex DataLens. URL: <https://datalens.tech/docs/> (дата обращения: 07.09.2026).